

Aplicación de Autocorrelación Espacial

Estudiante Yhack Bryan Aycaya Paco
Docente Dr. Fred Torres Cruz
Curso Estadística Espacial
Institución Universidad Nacional del Altiplano (UNA PUNO)

Resumen de los Artículos y su Convergencia con la Autocorrelación Espacial

Los tres artículos científicos, publicados en 2025, abordan fenómenos con heterogeneidad espacial en contextos ambientales y de salud pública, utilizando datos geospaciales para analizar patrones y factores impulsores. Cada uno integra la autocorrelación espacial como herramienta clave para detectar dependencias y agrupamientos geográficos, convergiendo en la idea de que los procesos no son aleatorios sino estratificados por gradientes espaciales (e.g., climáticos, socioeconómicos). Esta convergencia resalta cómo la autocorrelación complementa otros métodos (e.g., tendencias temporales, modelado cualitativo, detección de interacciones), permitiendo identificar hotspots y coldspots para intervenciones diferenciadas, alineadas con objetivos sostenibles como los SDGs. La autocorrelación espacial une los estudios al cuantificar similitudes vecinas, revelando sinergias multifactoriales y patrones persistentes a través de escenarios, lo que fortalece la evidencia para políticas regionales.

Descripción de los Artículos

- Art 1:** *'A remote sensing evidence on the marginality, stagementation and spatiotemporal heterogeneity of vegetation evolution characteristics in the Yinshan Mountains, China: Based on PKU GIMMS NDVI (1984–2022)' (Ecological Indicators)*. Este estudio examina la evolución de la vegetación en las Montañas Yinshan (YSMs), una zona ecológicamente vulnerable en China, destacando su fragilidad ante el cambio climático y actividades humanas, con mejoras recientes pero volatilidad persistente. La metodología utiliza datos de teledetección (PKU GIMMS NDVI, 1984–2022) con métodos como Theil-Sen/Mann-Kendall para tendencias, Hurst para sostenibilidad, correlaciones (Pearson/parcial) y residuales para impulsores, y autocorrelación espacial bivariable (Bi-SA) para patrones entre NDVI y clima.
- Art 2:** *'Assessing coastal exposure to Sea Level Rise: a coupled approach of qualitative modeling and spatial autocorrelation analysis' (Natural Hazard Research)*. Analiza la exposición costera al SLR en 25 km de la costa atlántica de Salé (Marruecos), enfatizando el rol mitigador de hábitats naturales y riesgos amplificados por geomorphology y clima, identificando el sur como más vulnerable. La metodología emplea el modelo InVEST para índice cualitativo de exposición (basado en variables bio-geo-físicas rankeadas), cuatro escenarios (con/sin hábitats, actual/futuro SLR), y autocorrelación espacial (Moran's I global/local, LISA) para clustering.
- Art 3:** *'Spatial stratified heterogeneity of mumps incidence in China: a Geodetector-based analysis of driving factors' (Frontiers in Public Health)*. Investiga la incidencia de paperas en 31 provincias chinas en 2020, revelando clustering espacial y factores como demografía infantil, con énfasis en estrategias regionales para controlar brotes. La metodología usa descriptivos, autocorrelación espacial (Global Moran's I, LISA, Getis-Ord Gi*), y Geodetector para poder explicativo (PD), interacciones y riesgos estratificados de 12 factores socioeconómicos/ambientales.

Definición de Autocorrelación Espacial

La autocorrelación espacial es un concepto estadístico que mide el grado de similitud entre valores observados en ubicaciones geográficas cercanas, asumiendo que "todo está relacionado con todo, pero las cosas cercanas están más relacionadas que las distantes" (Ley de Tobler). Se cuantifica mediante índices como Moran's I (global: dependencia general, rango -1 a 1; local: clusters H-H/L-L), donde valores positivos indican clustering positivo (similares agrupados), negativos dispersión, y 0 aleatoriedad. Fórmulas clave incluyen: $I = \frac{\sum \sum W_{ij}}{n} \frac{\sum \sum W_{ij} (x_i - \bar{x})(x_j - \bar{x})}{\sum (x_i - \bar{x})^2}$, con significancia por Z-score. Converge con otros métodos al revelar heterogeneidad estratificada, complementando correlaciones lineales o modelados al incorporar pesos espaciales (W_{ij} basados en contigüidad/distancia).

Aplicación de Autocorrelación Espacial en los Artículos

Art 1: En este artículo, la autocorrelación espacial se aplica mediante análisis bivariado (Bi-SA) para explorar la relación espacial entre NDVI (índice de vegetación) y factores climáticos como precipitación y temperatura. Usa Moran's I global (0.88 para NDVI-precipitación, $P < 0,01$) y LISA local para clusters (H-H en sureste con alta correlación positiva; disperso negativo para temperatura, Moran's I=-0.46). La aplicación revela sensibilidad espacial de la vegetación a la precipitación (agrupada positivamente), convergiendo con correlaciones parciales ($r = 0,25$ positivo en 85

Art 2: Aquí, la autocorrelación espacial evalúa el clustering del índice de exposición (EI) costera, usando Moran's I global (0.7-0.8, $Z > 18$, $P < 0,001$) y LISA para patrones locales (H-H 16-19 % en sur vulnerable; L-L 14-19 % en norte protegido). Aplicada a cuatro escenarios InVEST (con/sin hábitats, SLR), muestra clustering estable (e.g., alto riesgo en Sidi Moussa por geomorphology), convergiendo con el modelado cualitativo para validar mitigación de hábitats (reducción EI 30-50 %), destacando dependencia espacial persistente y necesidad de gestión diferenciada.

Art 3: La autocorrelación espacial se aplica para mapear heterogeneidad en incidencia de paperas, con Global Moran's I (0.399, $P < 0,001$), LISA (H-H en oeste como Qinghai; L-L en noreste como Jilin) y Getis-Ord G_i^* (hotspots oeste 90-99 % confianza). Converge con Geodetector (PD interacciones ≥ 0.5 , e.g., PIB-iletrismo=0.88) al confirmar clustering impulsado por factores (e.g., ratio infantil $PD = 0,54$), revelando gradiente oeste-este y apoyando estrategias targeted en hotspots occidentales.

Código en R

```
1 # Instalacion de paquetes necesarios
2 # install.packages(c("spdep", "rgdal", "GD", "trend", "sp", "partial.ci"))
3
4 # Cargar librerias
5 library(spdep)      # Autocorrelacion espacial
6 library(rgdal)      # Manejo de datos espaciales
7 library(GD)         # Geodetector
8 library(trend)      # Theil-Sen y Mann-Kendall
9 library(sp)         # Clases espaciales
10 library(partial.ci) # Correlacion parcial
11
12 # Carga y preprocesamiento de datos
13 data(meuse)         # Dataset de ejemplo
14 coordinates(meuse) <- ~x + y # Definir coordenadas
15 proj4string(meuse) <- CRS("+init=epsg:28992") # Proyeccion
16 meuse$zinc_class <- cut(meuse$zinc, breaks = quantile(meuse$zinc, probs = seq(0, 1,
17   0.2)), labels = 1:5) # Discretizacion
18
19 # Analisis de tendencias
20 mk_result <- mk.test(meuse$zinc) # Mann-Kendall
21 sen_slope <- sens.slope(meuse$zinc) # Theil-Sen
22 library(fracdiff)
23 hurst_exp <- hurstexp(meuse$zinc) # Hurst exponent
24
25 # Autocorrelacion espacial
26 nb <- poly2nb(meuse) # Vecinos
27 lw <- nb2listw(nb, style = "W") # Pesos
28 moran_global <- moran.test(meuse$zinc, lw) # Moran's I global
29 moran_local <- localmoran(meuse$zinc, lw) # LISA
30 gi_star <- localG(meuse$zinc, lw) # Getis-Ord  $G_i^*$ 
31 moran_biv <- moran.test(meuse$zinc, lw) # Bivariado (ajustar)
32
33 # Correlaciones y residuales
34 pearson_cor <- cor.test(meuse$zinc, meuse$cadmium) # Pearson
35 partial_cor <- pcor.test(meuse$zinc, meuse$cadmium, meuse$copper) # Partial
36 lm_model <- lm(zinc ~ cadmium + copper, data = meuse) # Modelo
37 residuals_lm <- residuals(lm_model) # Residuales
```

```

38 # Modelado cualitativo y factores
39 meuse$rank_zinc <- ntile(meuse$zinc, 5) # Rank
40 meuse$rank_cad <- ntile(meuse$cadmium, 5) # Rank
41 meuse$exposure_index <- (meuse$rank_zinc * meuse$rank_cad)^(1/2) # Indice
42 gd_data <- data.frame(Y = meuse$zinc_class, X1 = meuse$cadmium, X2 = meuse$copper)
43 gd_result <- gd(Y ~ X1 + X2, data = gd_data) # Geodetector
44 gd_interact <- gdinteract(Y ~ X1 + X2, data = gd_data) # Interacciones
45
46 # Analisis de escenarios
47 meuse$exposure_no_hab <- meuse$rank_zinc # Escenario sin habitat
48
49 # Visualizacion y validacion
50 plot(meuse, col = moran_local[,1]) # Mapa LISA
51 summary(gd_result) # Resumen
52 print(moran_global) # Resultados
53 print(gd_interact) # Interacciones

```

Listing 1: Código en R basado en la metodología de los artículos

Conclusiones

La convergencia en el uso de la autocorrelación espacial en los tres artículos demuestra su eficacia para capturar heterogeneidad espacial estratificada, desde patrones vegetales y exposición costera hasta incidencia de enfermedades. Al integrar Moran's I y LISA con métodos complementarios (e.g., Theil-Sen, InVEST, Geodetector), los estudios identifican clustering significativo (e.g., H-H en zonas vulnerables), validando interacciones multifactoriales (e.g., clima-hábitat, PIB-iletrismo) y ofreciendo evidencia para políticas regionales. Esta metodología, replicable con datos geospaciales, fortalece la planificación sostenible en contextos de cambio climático y salud pública.